# PROJET 5 Olist Segmentation Client modélisation ML non supervisée



Catherine BRICE
Openclassrooms formation Data Scientist
Le 03/02/2022

#### Plan du document

- Introduction
- Cleaning et analyse exploratoire des données
- Pistes de modélisation et modèle final
- Contrat de maintenance

#### Introduction

Olist : plateforme brésilienne de e-commerce

Buts du projet :

Comprendre ses utilisateurs d'un point de vue marketing


Segmenter les clients par modélisation non supervisée

Proposer un contrat de maintenance afin de mieux orienter la stratégie marketing

#### Les datas issues de Olist

A partir d'une base de données anonymisée de Olist, historique de commandes, produits achetés, commentaires de satisfaction, localisation des clients de 2016 à

2018



#### Les dataframes : shapes

Dataframes	Shapes
customers	(99441, 5)
geolocation	(1000163, 5)
items	(112650, 7)
payments	(103886, 5)
reviews	(99224, 7)
orders	(99441, 8)
products prod_cat_name_tr	(32951, 9)
sellers	(3095, 4)
products_trans	(71, 2)

Nettoyage des données	Actions
codes postaux clients	supprimer les doublons zipcode, 1 Zip_code = plusieurs latitudes et longitudes, 19608 Zip_code après fusion
supprimer les variables inutiles ou redondantes	'review_comment_title', 'review_comment_message' 'product_photos_qty','product_weight_g','product_length_cm','product_height_cm','product_width_cm' 'payment_sequential' 'product_category_name' 'product_name_lenght' 'product_description_lenght' 'shipping_limit_date', 'geolocation_zip_code_prefix', 'geolocation_city', 'geolocation_state'
sélection des commandes livrées	merged = merged [merged['order_status'] == 'delivered']
valeurs manquantes supprimées	order_approved_at 160 order_delivered_carrier_date 1783 order_delivered_customer_date 2965
accents sur sao paulo à supprimer	
Variables dates à retravailler pd.to_datetime Variables temps	merged['order_purchase_timestamp'] merged['order_approved_at'] merged['order_delivered_carrier_date'] merged['order_delivered_customer_date'] = merged['order_estimated_delivery_date'] = merged['shipping_limit_date'] = merged['review_creation_date'] = merged['review_answer_timestamp'] =  merged["order_months"] - merged["order_months2"] - merged["order_year"] - merged["order_date"] merged['delivered_time'] = (merged['order_delivered_customer_date'] - merged['order_purchase_timestamp']) dt days

#### Fusion des dataframes

0]: merged.head()

order_id	customer_id	order_status	order_purchase_timestamp	order_approved_at	order_delivered_ca
0 e481f51cbdc54678b7cc49136f2d6af7	9ef432eb6251297304e76186b10a928d	delivered	2017-10-02 10:56:33	2017-10-02 11:07:15	2017-10-
1 e481f51cbdc54678b7cc49136f2d6af7	9ef432eb6251297304e76186b10a928d	delivered	2017-10-02 10:56:33	2017-10-02 11:07:15	2017-10-
2 e481f51cbdc54678b7cc49136f2d6af7	9ef432eb6251297304e76186b10a928d	delivered	2017-10-02 10:56:33	2017-10-02 11:07:15	2017-10-
3 e481f51cbdc54678b7cc49136f2d6af7	9ef432eb6251297304e76186b10a928d	delivered	2017-10-02 10:56:33	2017-10-02 11:07:15	2017-10-
4 e481f51cbdc54678b7cc49136f2d6af7	9ef432eb6251297304e76186b10a928d	delivered	2017-10-02 10:56:33	2017-10-02 11:07:15	2017-10-

5 rows × 44 columns

#### Suppression des NaN: There is 5.46% nan values


```
column
                                                                  column nan %
                       order_id 0.000000
                                                               order id
                                             product_name_lenght
product_description_lenght
product_photos_qty
product_weight_g
product_length_cm
                   customer id 0.000000
                  order_status 0.000000
     order_purchase_timestamp 0.000000
order_estimated_delivery_date 0.000000
                  payment_type 0.003359
           payment_sequential 0.003359
                                                       product_height_cm
  product_width_cm
         payment installments 0.003359
                 payment_value 0.003359
                                             product_category_name
review_answer_timestamp
             order_approved_at 0.148929
                customer state 0.180282
                 customer city 0.180282
     customer_zip_code_prefix 0.180282
                                                        seller state
            customer unique id 0.180282
                                                        customer_unique_id
               geolocation lat 0.180282
                                                  \verb"customer_zip_code_prefix"
             geolocation_state 0.180282
                                                            customer city
              geolocation_city 0.180282
                                                           customer state
  geolocation_zip_code_prefix 0.180282
                                             geolocation_zip_code_prefix
               geolocation lng 0.180282
                                                        geolocation_city
                 order_item_id 0.709371
                                                       geolocation_state
                 freight value 0.709371
                                                   seller_city
review_creation_date
                    product_id 0.709371
                     seller_id 0.709371
                                                  review_comment_message
           shipping limit date 0.709371
                          price 0.709371
                  seller state 0.709371
                   seller_city 0.709371
       seller_zip_code_prefix 0.709371
                                                  order_purchase_timestamp
              product weight g 0.723928
             product length cm 0.723928
                                              order_delivered carrier date
             product_height_cm 0.723928
                                             order delivered customer_date
             product_width_cm 0.723928
                                                              product id
                                                                seller id
```

#### Dataframe finale 'merged'

```
]: merged.info()
<class 'pandas.core.frame.DataFrame'>
Int64Index: 169358 entries, 0 to 178608
Data columns (total 36 columns):
                            Non-Null Count Dtype
    Column
____
                          169358 non-null object
    order id
 1 customer id
                           169358 non-null object
 2 order status
                           169358 non-null object
 3 order purchase timestamp 169358 non-null datetime64[ns]
                 169358 non-null object
 4 order item id
 5 product id
                         169358 non-null object
  seller id
                           169358 non-null object
                          169358 non-null float64
 7 price
 8 freight value 169358 non-null float64
 9 payment sequential 169358 non-null float64
                           169358 non-null object
 10 payment_type
 11 payment_installments 169358 non-null float64
12 payment value
                           169358 non-null float64
                     169358 non-null object
    review id
    review_score 169358 non-null float64
15 review_comment_title 169358 non-null object
16 review_comment_message 169358 non-null object
17 product_weight_g 169358 non-null float64
    product_category_name 169358 non-null object
    seller_zip_code_prefix 169358 non-null object
                 169358 non-null object
169358 non-null object
    seller city
 21 seller state
    customer unique id 169358 non-null object
    customer zip code prefix 169358 non-null object
    customer_city 169358 non-null object
 25 customer state
                           169358 non-null object
                          169358 non-null float64
    geolocation lat
```

### Analyse des données







14678




#### Les années de vente



#### Les mois d'achats clients




#### Les jours d'achats clients



#### Concentration des clients




#### 6 grands groupes d'états acheteurs




## Les prix des produits


Distribution des prix des produits



### Le cout du freight


#### Distribution des couts de transport






#### Les valeurs de transactions


#### Distribution des valeurs des transactions




## Les moyens de paiement




#### Etalement des paiements




#### Les catégories de segmentation



#### Satisfaction des clients



#### Reactivité des clients




#### Describe de la dataframe


	price	freight_value	payment_sequential	payment_installments	payment_value	review_score	product_weight_g	delivered_time	revie
count	169358.000000	169358.000000	169358.000000	169358.000000	169358.000000	169358.000000	169358.000000	169358.000000	1693
nean	118.975550	19.573251	1.093630	2.914867	169.889156	4.089172	2091.787958	11.654720	
std	180.427053	15.438949	0.718767	2.765940	253.957683	1.340083	3750.961036	9.210226	
min	0.850000	0.000000	1.000000	0.000000	0.000000	1.000000	0.000000	0.000000	
25%	39.900000	12.790000	1.000000	1.000000	60.000000	4.000000	300.000000	6.000000	
50%	73.900000	16.110000	1.000000	1.000000	107.440000	5.000000	700.000000	9.000000	
75%	130.000000	20.850000	1.000000	4.000000	188.335000	5.000000	1800.000000	15.000000	
max	6735.000000	409.680000	26.000000	24.000000	13664.080000	5.000000	40425.000000	208.000000	5′
									>

#### Evolution des commandes journalières


#### Evolution du nombre de commandes journalières




#### Les achats sur les mois de l'année




## Ou se situent les meilleurs clients (payment > 3000) ?





#### Satisfaction client et lieux de résidence



#### Heatmap



- 1.0

- 0.8

- 0.6

- 0.4

- 0.2

- 0.0

- -0.2

#### One hot encoding et standardisation

```
: numerical features = list(encoding data.select dtypes(include=['int64','float64', 'uint8']).columns)
  numerical features
['total orders',
 'total payment',
 'total freight',
 'average payment sequential',
 'average payment installments',
 'average review score',
 'average delivery late',
 'average delivery time',
 'average review delay',
 'favorite sale month',
 'books cds media',
 'fashion clothing accessories',
 'flowers gifts',
 'groceries food drink',
 'health beauty',
 'home furniture',
 'other'.
 'sport',
 'technology',
 'toys baby',
 'customer state Minas Gerais',
 'customer state Parana',
 'customer_state_Rio_Grande_do_Sul',
 'customer state Rio de Janeiro',
 'customer state Sao Paulo',
 'customer state other states']
```

#### Aggregats clients

Groupons les données moyenne ou totales par client

Nombre moyen d'articles par commande pour chaque client


Regroupement des consommateurs suivant les nouvelles catégories de produits

<class 'pandas.core.frame.DataFrame'> Index: 91211 entries, 0000366f3b9a7992bf8c76cfdf3221e2 to f Data columns (total 23 columns): Non-Null Count Column total orders 91211 non-null int64 91211 non-null float64 total payment total freight 91211 non-null float64 91211 non-null float64 average payment sequential average payment installments 91211 non-null float64 average review score 91211 non-null float64 91211 non-null float64 average delivery late average delivery time 91211 non-null float64 average review delay 91211 non-null float64 favorite sale month 91211 non-null int64 books cds media 91211 non-null float64 fashion clothing accessories 91211 non-null float64 flowers gifts 91211 non-null float64 groceries food drink 91211 non-null float64 health beauty 91211 non-null float64 home furniture 91211 non-null float64 other 91211 non-null float64 sport 91211 non-null float64 technology 91211 non-null float64 toys baby 91211 non-null float64 total items 91211 non-null float64 average nb items 91211 non-null float64 customer state 91211 non-null object


dtypes: float64(20), int64(2), object(1)

memory usage: 16.7+ MB

#### Heatmap des corrélations linéaires




## Clustering Kmeans : méthode du coude pour déterminer le meilleur K



le point du coude est celui du nombre de clusters à partir duquel la variance ne se réduit plus significativement K = 7

## Coefficients de silhouettes complémentaire pour déterminer le K optimal



Ici un K optimal serait 7 d'après les coefficients de silhouette

#### Les 7 premiers clusters suivant leurs moyennes


	total_orders	total_payme nt	total_freight	average_payment_sequential	average_payment_installments	average_review_score	average_
kmeans_label							
0	0.002462	0.010813	0.010105	0.001566	0.110056	0.825918	
1	0.002642	0.008454	0.011926	0.001537	0.125845	0.795626	
2	0.002732	0.009214	0.012250	0.002234	0.126405	0.740430	
3	0.001616	0.008833	0.009275	0.001437	0.082448	0.789203	
4	0.002232	0.011685	0.017798	0.001835	0.132391	0.762177	
5	0.003378	0.010179	0.013574	0.002334	0.125682	0.796730	
6	0.002496	0.008815	0.011873	0.001703	0.126383	0.801990	

7 rows × 27 columns


e

### Radar chart des clusters projetés

#### Comparaison des moyennes par variable des clusters



#### Nouveau Kmeans sans les variables Etats



# K vaut 6 et le score silhouette moyen est passé à 0.62

### Nouveau Radar chart projeté

#### Comparaison des moyennes par variable des clusters


Cluster 0

Cluster 1

Cluster 2

Cluster 3
Cluster 4

Cluster 5



Clustering par rapport à des variables de

sélection

groupe 0 : clients très satisfaits - bon délai livraison - bcp paiements échelonnés


groupe 1 : clients mécontents - délais livraison élevés - bcp paiements échelonnés

groupe 2 : peu de paiements échelonnés) - la plus basse saison mensuelle d'achat


groupe 3 : clients plutôt satisfaits - livraison moyenne - achète dans une autre période de l'année

groupe 4 : clients plutôt satisfaits - paiements échelonnés moyens - mois forts d'achat - livraison moyenne groupe 5 : bon paiements échelonnés - mois forts d'achat -

groupe 5 : bcp paiements échelonnés - mois forts d'achat - assez satisfaits - livraison longue





### Reduction de dimension avec PCA



Il faut donc conserver 9 axes principaux pour expliquer la variance à 95%.


#### Silhouettes score et distances inter clusters





### Radar chart sur les variables projetées





La PCA améliore peu la qualité du modèle (silhouette score reste à 0.62)

#### Scores de stabilité des kmeans à l'initialisation


Scores de stabilité à l'initialisation

Itera	ation	FitTime	Inertia	Homo	ARI	AMI
Iter	0	0.749s	15154	0.616	0.671	0.758
Iter		0.109s	15154	0.616	0.671	0.758
Iter	2	0.131s	15154	0.616	0.671	0.758
Iter	3	0.091s	21465	0.429	0.390	0.597
Iter	4	0.101s	15154	0.616	0.671	0.758
Iter	5	0.121s	15154	0.616	0.671	0.758
Iter	6	0.093s	21465	0.429	0.390	0.597
Iter	7	0.142s	15154	0.616	0.671	0.758
Iter	8	0.101s	15154	0.616	0.671	0.758
Iter	9	0.111s	15154	0.616	0.671	0.758
Iter	10	0.093s	21465	0.429	0.390	0.597
Iter	11	0.123s	15154	0.616	0.671	0.758
Iter	12	0.123s	15154	0.616	0.671	0.758
Iter	13	0.131s	15154	0.616	0.671	0.758
Iter	14	0.131s	15154	0.616	0.671	0.758

Les différentes itérations montrent des inerties proches, une bonne homogénéité et un score AMI acceptable.

La stabilité à l'initialisation du modèle K-Means est bonne

### DBSCAN: choix de Epsilon



Estimated number of clusters: 34

Estimated number of noise points: 33435

Silhouette Coefficient: 0.144

DBSCAN semble pas adapté pour notre échantillon Les données sont trop éparpillées

## Stabilité du clustering dans le temps

La période complète des commandes porte sur 23 mois : 2016-10-03 au 2017-10-03

Principe : Recalculer toutes les features en fonction d'une période initiale donnée (12 mois depuis la plus petite date de commande) Ensuite rajouter successivement (10 fois) des périodes de 1 mois

Clustering sans les catégories produits et les Etats des clients

'kmeans\_init' est le modèle de base issu de la clusterisation de la Baseline

Pour calculer la stabilité des clusters, on calcule pour chaque base périodique, le score ARI entre la prédiction de la database périodique sur le modèle initiale 'kmeans\_init' et le label issu du nouveau modèle issu de la clusterisation de la database périodique.

### Baseline : 12 mois depuis la plus petite période de commande

```
<class 'pandas.core.frame.DataFrame'>
Index: 25230 entries, 0000f46a3911fa3c0805444483337064 to ffffd2657e2aad2907e67c3e9daecbeb
Data columns (total 28 columns):
  # Column
                                                                                                                    Non-Null Count Dtype
             total orders
   2 total freight

      3
      average_payment_sequential
      25230 non-null float64

      4
      average_payment_installments
      25230 non-null float64

      5
      average_review_score
      25230 non-null float64

      6
      average_delivery_late
      25230 non-null float64

      7
      average_delivery_time
      25230 non-null float64

      8
      average_review_delay
      25230 non-null float64

      9
      favorite_sale_month
      25230 non-null float64

      10
      books_cds_media
      25230 non-null float64

      11
      fashion_clothing_accessories
      25230 non-null float64

      12
      flowers_gifts
      25230 non-null float64

      13
      groceries_food_drink
      25230 non-null float64

      14
      health_beauty
      25230 non-null float64

      15
      home_furniture
      25230 non-null float64

      16
      other
      25230 non-null float64

      17
      sport
      25230 non-null float64


                                                                              25230 non-null float64
              sport
 17 sport 25230 non-null float64
18 technology 25230 non-null float64
19 toys_baby 25230 non-null float64
20 total_items 25230 non-null float64
21 mean_nb_items 25230 non-null float64
22 customer_state_Minas_Gerais 25230 non-null uint8
23 customer_state_Parana 25230 non-null uint8
  24 customer state Rio Grande do Sul 25230 non-null uint8
  25 customer_state_Rio_de_Janeiro 25230 non-null uint8
26 customer_state_Sao_Paulo 25230 non-null uint8
27 customer_state_other_states 25230 non-null uint8
dtypes: float64(20), int64(2), uint8(6)
memory usage: 4.6+ MB
```

# Kmeans de la Baseline : 6 clusters par leurs moyennes

	total_orders	total_payment	total_freight	average_payment_sequential	$average\_payment\_installments$	average_review_score	average_delivery
kmeans_label_init							
0	0.006910	0.008443	0.011885	0.001899	0.097049	0.836497	0.41
1	0.007359	0.009537	0.014528	0.003062	0.124725	0.787445	0.41
2	0.002824	0.010313	0.010918	0.001929	0.081423	0.798009	0.41
3	0.005763	0.010419	0.011015	0.001895	0.121908	0.813362	0.40!
4	0.002669	0.014481	0.011070	0.002185	0.136371	0.831127	0.412
5	0.004806	0.011666	0.012764	0.002285	0.115240	0.809190	0.41

6 rows × 22 columns

#### Contrat de maintenance



Sur ce plot des scores ARI par périodes glissantes de 1 mois , plateau après 4 mois puis la courbe décroit jusqu'à la période 9 mois. Elle change d'allure (croissance sur 4 mois) après 9 périodes glissantes de 1 mois. Prévoir la maintenance du programme de segmentation tous les 9 mois dans un premier temps, puis re-tester cette stabilité temporelle au fil du temps afin de l'affiner. Les segments clients seront redéfinis à chaque maintenance. 'average\_review\_score' et 'favorite sale month' sont des variables qui peuvent avoir un impact sur les clusters.